

博采众长，人工智能最新研究成果解读

人工智能文献推荐系列之一

报告摘要:

● 人工智能研究领域百花齐放

得益于数据、算力和算法的提升，人工智能在工业应用和学术研究上都取得了飞速发展。目前，大量的人工智能技术已经接近甚至超过人类水平，其中，机器翻译已经可以媲美人类翻译，图像识别准确率已经超过了人眼的识别水平，AlphaGo 等领域专家系统水平已经领先最强的人类选手。

近两年，人工智能学术研究的前沿领域集中在自然语言处理、计算机视觉、强化学习、迁移学习等方向。每年有大量优秀的学术论文发表在人工智能相关领域的顶级会议中。

本报告将跟进人工智能顶级会议上的优秀论文和知名人工智能研究团队的最新工作进展，解读近期人工智能方向最有影响力的一批论文。

● 人工智能在研究和应用上都取得了重要进展

2018 年，自然语言处理领域的语言模型预训练取得了重大突破，相继产生了 NAACL 2018 最佳论文提出的 ELMo 模型、OpenAI 团队提出的 GPT 模型、和谷歌 AI 团队提出的 BERT 模型。其中，BERT 模型是目前最先进的自然语言处理预训练技术，该模型刷新了 11 项自然语言处理任务的最优性能记录。而在自然语言处理的下游应用领域，问答和对话技术、文本生成、文本摘要、机器翻译等是近年来的热点问题。

计算机视觉方向近年来的研究热点主要是在图像检测、图像分割、图像标注和图像生成等方向。在图像检测和分割方面，Facebook 研究团队提出的 Mask R-CNN 模型获得了 2017 年 ICCV 会议的最佳论文。CVPR 2018 最佳论文提出的 Taskonomy 方法给出了一种优化迁移学习的策略，可以量化不同视觉任务之间的关联，并利用这些关联来最优化学习策略的研究。

在关系推理方面，DeepMind 等团队联合发布的论文提出了一种图网络框架，推广并扩展了各种神经网络方法，为神经网络的关系推理提供了新的思路。DeepMind 团队的另一篇论文将关系推理与强化学习方法结合，获得了明显的性能提升，为强化学习开辟了新的方向。

● 风险提示

本报告为人工智能学术论文解读，不构成任何投资建议。

分析师:

文巧钧



SAC 执证号: S0260517070001



SFC CE No. BNI358



0755-82797057



wenqiaojun@gf.com.cn

分析师:

安宁宁



SAC 执证号: S0260512020003



SFC CE No. BNW179



0755-23948352



anningning@gf.com.cn

分析师:

罗军



SAC 执证号: S0260511010004



020-87579006



luojun@gf.com.cn

请注意，罗军并非香港证券及期货事务监察委员会的注册持牌人，不可在香港从事受监管活动。

相关研究:

人工智能在资产管理行业的应用和展望 2018-07-30

联系人:

童炯潇 020-87572092

tongjiangxiao@gf.com.cn

目录索引

一、前言	4
二、论文: BERT	5
1、论文信息	5
2、论文主要内容	6
三、论文: LEARNING TO ASK GOOD QUESTIONS	7
1、论文信息	7
2、论文主要内容	7
四、论文: SENTIGAN	9
1、论文信息	9
2、论文主要内容	9
五、论文: ABSTRACTIVE TEXT SUMMARIZATION	11
1、论文信息	11
2、论文主要内容	11
六、论文: MASK R-CNN	13
1、论文信息	13
2、论文主要内容	13
七、论文: ADAPTIVE AFFINITY FIELDS	18
1、论文信息	18
2、论文主要内容	18
八、论文: TASKONOMY: DISENTANGLING TASK TRANSFER LEARNING	21
1、论文信息	21
2、论文主要内容	21
九、论文: GRAPH NETWORKS	23
1、论文信息	23
2、论文主要内容	23
十、论文: RELATIONAL DEEP REINFORCEMENT LEARNING	25
1、论文信息	25
2、论文主要内容	25
十一、论文: THE TRADE-OFFS OF LARGE SCALE LEARNING	28
1、论文信息	28
2、论文主要内容	28

图表索引

图 1: BERT 模型结构.....	6
图 2: BERT 测试性能.....	7
图 3: 根据澄清性问题补充信息的示例.....	8
图 4: 模型的整体框架.....	9
图 5: SentiGAN 模型框架.....	10
图 6: 生成文本的情感准确度对比.....	10
图 7: 引入主题信息的卷积神经网络结构.....	12
图 8: 三种 ROUGE 在 Gigaword 语料库中的准确度 (左) 及其内部测试集的准确度 (右)	12
图 9: 三种 ROUGE 在 DUC-2004 中的准确度 (左) 和在 LCSTS 中的准确度 (右) (右下角的分数分为基于单词的分数和基于字符的分数)	13
图 10: 计算机视觉 (Computer Vision) 领域的常见任务	14
图 11: Mask R-CNN 能够处理的视觉任务.....	15
图 12: R-CNN 目标检测系统框架.....	16
图 13: Fast R-CNN 目标检测系统框架.....	16
图 14: Faster R-CNN 目标检测系统框架.....	17
图 15: Mask R-CNN 目标检测系统框架	17
图 16: AAF 方法概述	19
图 17: CRF、GAN 和 AAF 方法的主要区别.....	19
图 18: AAF 方法以 PASCAL VOC 2012 数据集, pixel-wise mIoU 在验证集 (一)、instance-wise mIoU 在验证集 (二)、boundary detection metrics 在验证集 (三) 上的表现	20
图 19: 以 Cityscapes 为训练集, 以 GTA5 为测试集, AAF 与基准模型的比较 ..	20
图 20: 一个通过计算任务分类得到的示例任务结构图	22
图 21: Taskonomy 计算过程图	22
图 22: 不同系统的图网络描述	24
图 23: Box-World 智能体架构.....	26
图 24: Box-World 观察值示例 (左)、基本图结构 (中) 和训练曲线 (右)	26
图 25: RRL 的泛化能力比较	27
图 26: StarCraft II 游戏中各类动作得分	28

一、前言

得益于数据、算力和算法的提升，人工智能在工业应用和学术研究上都取得了飞速发展。目前，大量的人工智能技术已经接近甚至超过人类水平，其中，机器翻译已经可以媲美人类翻译，图像识别准确率已经超过了人眼的识别水平，AlphaGo等领域专家系统水平已经领先最强的人类选手。

近两年，人工智能学术研究的前沿领域集中在自然语言处理(Natural Language Processing, NLP)、计算机视觉(Computer Vision, CV)、强化学习(Reinforcement Learning, RL)、迁移学习(Transfer Learning)等方向。每年有大量优秀的学术论文发表在人工智能相关领域的顶级会议中：包括IJCAI(International Joint Conference on Artificial Intelligence, 人工智能顶级会议)、NeurIPS(Conference and Workshop on Neural Information Processing Systems, 人工智能顶级会议)、ACL(Annual Meeting of the Association for Computational Linguistics, 计算语言学顶级会议)、NAACL(Annual Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 计算语言学顶级会议)、ICCV(IEEE International Conference on Computer Vision, 计算机视觉顶级会议)、CVPR(Conference on Computer Vision and Pattern Recognition, 计算机视觉顶级会议)、ECCV(European Conference on Computer Vision, 计算机视觉顶级会议)等。

本报告将跟进人工智能顶级会议上的优秀论文和知名人工智能研究团队的最新工作进展，解读近期人工智能方向最有影响力的一批论文。

自然语言处理领域在2018年取得了重要进展。模型预训练是提高神经网络性能的有效手段。对于计算机视觉领域的研究人员来说，在ImageNet数据集上预训练模型然后用自己的任务专用数据训练模型已经成了行业的有效手段。但在自然语言处理领域，由于文本数据的多样化、非结构化和充斥着噪音的特点，预训练语言模型是一件不容易实现的任务。2018年，语言模型预训练方向取得了重大突破，相继产生了NAACL 2018最佳论文提出的ELMo模型、OpenAI团队提出的GPT模型和谷歌AI团队提出的BERT模型。其中，BERT模型是目前最先进的自然语言处理预训练技术，该模型刷新了11项自然语言处理任务的最优性能记录。本报告第二节将详细介绍BERT模型。

而在自然语言处理的下游应用领域，问答和对话技术、文本生成、文本摘要、机器翻译等是近年来的热点问题。在问答和对话技术方面，2018年的ACL会议最佳论文建立了一个神经网络模型来排序澄清性问题，以帮助机器提出更有价值的问题。在自然语言生成方面，2018年的IJCAI会议的杰出论文提出了一种自然语言处理领域的生成式对抗网络(GAN)，即SentiGAN。目前，文本的情感分类已经可以实现不错的准确度，但是情感文本生成依然是一大挑战。SentiGAN模型通过对抗训练，使用判别器来指导生成器，可以生成不同情感类别的文本。在文本摘要方面，腾讯等机构合作在IJCAI 2018发表的论文采用卷积神经网络结合注意力机制进行文本自动摘要，取得了不错的进展。本报告第三节到第五节将依次介绍这三篇论文。

图像识别是计算机视觉领域的传统研究内容，从2015年微软的何恺明团队提出残差神经网络(Residual Network)结构之后，计算机图像识别的准确度已经超过了人类水平。近年来，计算机视觉方面主要的研究热点是在图像检测、图像分割、

图像标注和图像生成等方向。

在图像检测和分割方面，现任职于Facebook的何恺明提出了Mask R-CNN模型，获得了2017年ICCV会议的最佳论文。Mask R-CNN在COCO系列挑战赛的三个分支中都获得了最佳成绩，包括实例分割、边界对象检测和人体关键点检测。加州大学伯克利分校研究团队发表的Adaptive Affinity Fields模型将自适应相似场的概念引入图像的语义分割模型中，并通过对抗训练来学习具有自适应范围的局部关系，为深度学习中的结构建模提供了新的视角。本报告第六节和第七节将介绍这两篇论文。

迁移学习是机器学习中的一类方法，它可以把给一个任务开发的机器学习模型重新用在另一个不同的任务中，并作为该任务模型的起点。由于在计算机视觉和自然语言处理上，开发神经网络模型需要大量的计算和时间资源，而且特定任务的训练样本一般会较少。所以，预训练的模型通常会被重新用作计算机视觉和自然语言处理任务的起点。因此，迁移学习是深度学习方向的一种常见方法。CVPR 2018最佳论文提出的Taskonomy（Task Taxonomy的简写）方法给出了一种优化迁移学习的策略。Taskonomy是一项量化不同视觉任务之间关联，并利用这些关联来最优化学习策略的研究。如果两个视觉任务A、B具有关联性，那么在任务A中习得的表征理应可为解决任务B提供有效的信息。本报告第八节介绍了这篇论文。

深度学习擅长通过监督学习和无监督学习从数据中获取信息，进行特征学习和分类、回归等任务，但深度学习难以进行关系推理。近年来，研究者在这方面做了许多工作，提出了一些可行的方案。结合了深度学习的图神经网络将端到端学习与归纳推理相结合，有望解决深度学习无法处理的关系推理、可解释性等一系列问题。DeepMind等团队联合发布的论文提出了一种图网络框架，推广并扩展了各种神经网络方法，为神经网络的关系推理提供了新的思路。DeepMind团队的另一篇论文将关系推理与强化学习方法结合，获得了明显的性能提升，为强化学习开辟了新的方向。本报告的第九节和第十节分别介绍了这两篇与关系推理有关的论文。

此外，本报告介绍了NeurIPS 2018会议上获得时间检验奖的论文《The Trade-Offs of Large Scale Learning》。这是一篇基础理论方面的论文。这篇论文研究了机器学习中数据和计算之间的相互关系，显示了如果计算力受限但是能使用超大型数据集，对许多单独训练样本执行小量运算效率更高，而对数据子集进行大量计算的性能会不如前者。这篇论文充分显示了随机梯度下降算法的强大之处，大大推进了随机梯度下降算法在过去十年的发展。

二、论文：BERT

1、论文信息

论文：BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.

论文作者：Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova

论文来源：<https://arxiv.org/abs/1810.04805>

GitHub地址：<https://github.com/google-research/bert/>

2、论文主要内容

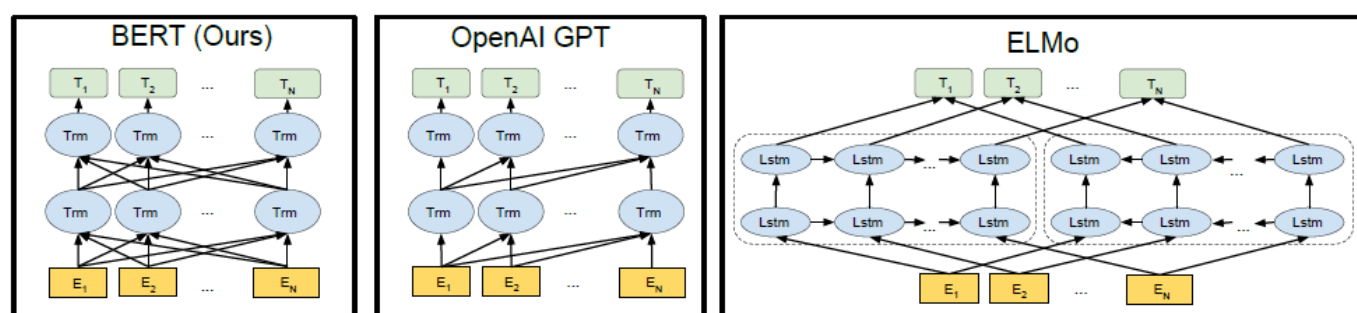
谷歌AI团队发布的BERT（Bidirectional Encoder Representations from Transformers）是一个通过大规模文本训练出来的预训练模型。由于自然语言处理（NLP）是一个具备不同任务的多样化领域，因此大多数任务特定数据集仅包含几千到几十万个人类标注的训练样例。然而，基于深度学习的NLP模型可以从更大量的数据中获益，在数百万或数十亿的带标签的训练样例中学习得到改善。为了帮助缩小在数据方面的差距，研究人员开发了各种技术，使用网络上无标签的文本训练一个通用的语言表示模型（称为预训练）。基于预训练模型在小数据的NLP任务（如问答和情感分析）上进行微调，与从头开始训练模型相比，可以显著提高准确度。

语言模型是NLP中的一种基础任务，其目标是给定一个序列文本，预测下一个位置上会出现的词。单向语言模型是常用的语言模型，从左到右“阅读”或者从右到左“阅读”。以另外两种获得很大成功的OpenAI GPT和ELMo两种语言模型结构为例，OpenAI GPT使用的是一个需要从左到右的受限的Transformer，而ELMo使用的是双向LSTM，虽然也是双向的，但是也只是在两个单向的LSTM的最高层进行简单的拼接。

BERT是同时考虑上下文进行语言理解的模型。BERT提出一种新的预训练目标：遮蔽语言模型（Masked Language Model, MLM），来克服语言模型中的单向性局限。MLM的灵感来自完形填空（Cloze）任务。MLM随机遮蔽模型输入中的一些Token，目标在于仅基于遮蔽词的语境来预测其原始词汇。

与从左到右的语言模型预训练不同，MLM目标允许表征融合左右两侧的语境，从而预训练一个深度双向Transformer。除了遮蔽语言模型之外，BERT还引入了一个“下一句预测”（Next Sentence Prediction）任务，可以和MLM共同预训练文本对的表示。

图1：BERT模型结构



数据来源：J Devlin, MW Chang, K Lee, K Toutanova 《BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding》，广发证券发展研究中心

从性能上来看，BERT是目前最先进的NLP预训练技术，刷新了11项NLP任务的最优性能记录。包括将GLUE基准推至80.4%（7.6%的绝对提升），将MultiNLI准确度提升到86.7%（5.6%的绝对提升）等。下图展示了两个BERT模型（BERT BASE

和BERT LARGE)的结果在9个GLUE测试中获得了最优的准确率，BERT模型都取得了最好的结果。

图2: BERT测试性能

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.9	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	88.1	91.3	45.4	80.0	82.3	56.0	75.2
BERT _{BASE}	84.6/83.4	71.2	90.1	93.5	52.1	85.8	88.9	66.4	79.6
BERT _{LARGE}	86.7/85.9	72.1	91.1	94.9	60.5	86.5	89.3	70.1	81.9

数据来源: J Devlin, MW Chang, K Lee, K Toutanova 《BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding》，广发证券发展研究中心

类似于残差神经网络在图像领域的巨大成功，BERT模型作为NLP中一种开创性的预训练模型，是一种里程碑式的工作。但是BERT模型的计算复杂度很高。论文中，训练BASE版本需要在16个TPU上，LARGE版本需要在64个TPU上训练4天。在其他硬件条件下，运行时间要长很多。因此，未来BERT更有可能作为一种初始化的工具被NLP中的研究者使用到。

三、论文: Learning to Ask Good Questions

1、论文信息

论文: Learning to Ask Good Questions: Ranking Clarification Questions Using Neural Expected Value

论文作者: Sudha Rao, Hal Daum'e III

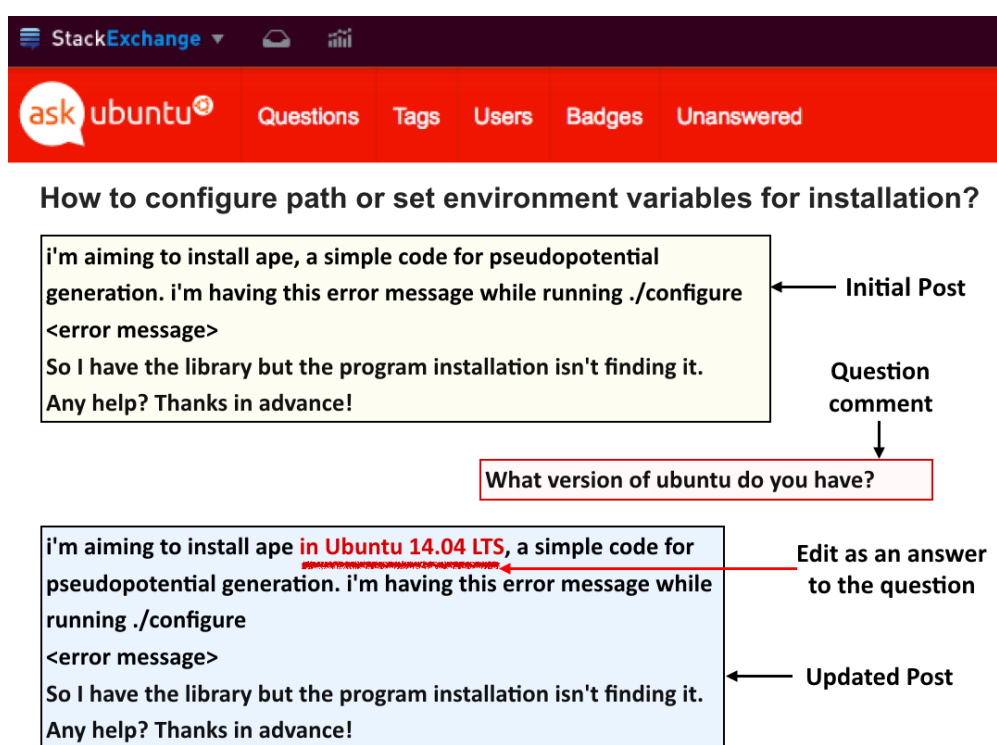
论文来源: <https://arxiv.org/pdf/1805.04655.pdf>

2、论文主要内容

该论文是ACL 2018的最佳论文之一，是由马里兰大学和微软研究院合作完成，旨在研究如何让机器学会提出有用的问题。

本文认为提问(Inquiry)是沟通的基础，如果机器不会提出问题，那么就无法高效与人协作。该论文建立了一个神经网络模型来排序澄清性问题(Clarification Questions)，以帮助机器提出更有价值的问题。

图3：根据澄清性问题补充信息的示例



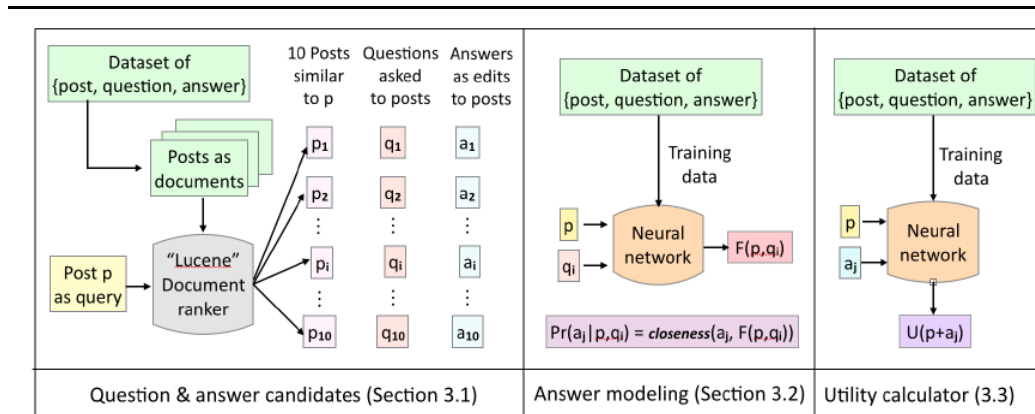
数据来源：S Rao, H Daume III 《Learning to Ask Good Questions: Ranking Clarification Questions Using Neural Expected Value》，广发证券发展研究中心

什么是澄清性问题？如上图所示，用户原始的帖子（Initial Post）想询问如何设置系统的环境变量，但是没有描述具体的场景。图中的“Question comment”就是一个典型的澄清性问题，提问者接受了这个问题，并对问题背景做了补充，说明这个澄清性问题有用。

该论文设计了这样一个模型，能够根据有用的程度对原始帖子的一系列候选澄清性问题进行排序。具体的应用场景是，当用户遇到问题，发贴求助时，系统会提出一系列澄清性问题来请求更多的信息，这些信息能够帮助回答者更好的了解这个问题，从而给出更加迅速、优质的回复。

模型受到完美信息期望值（Expected Value of Perfect Information）的启发，认为一个问题好不好，在于其预期的回答是否有用。模型的整体框架如下图所示，对于每一个提问的帖子 p ，通过文本检索系统Lucene在系统中找出与 p 最接近的10个帖子；在这10个帖子中出现的澄清性问题被列为问题候选集 Q ，因这些澄清性问题而对原始帖子作出的编辑（信息补全）被列为答案集 A 。对于每一个候选的澄清性问题 q_i ，通过神经网络计算得到答案的语义表达 $F(p, q_i)$ 并且计算候选答案 a_j 与 $F(p, q_i)$ 之间的距离。然后，在原帖 p 根据候选答案 a_j 进行更新后，计算这个帖子的可用性 $U(p + a_j)$ 。最后，根据每个候选问题 q_i 给予原帖 p 的预期的可用性，来对 Q 中的问题排序。

图4：模型的整体框架



数据来源：S Rao, H Daume III 《Learning to Ask Good Questions: Ranking Clarification Questions Using Neural Expected Value》，广发证券发展研究中心

该论文以StackExchange论坛上的帖子为基础，构建了包含7.7万个帖子的数据集。在其中500个样本上进行测试，结果显示该论文提出的模型能够获得显著高于基准的表现。

四、论文：SentiGAN

1、论文信息

论文：SentiGAN: Generating Sentimental Texts via Mixture Adversarial Networks

论文作者：Ke Wang, Xiaojun Wan


论文来源：<https://www.ijcai.org/proceedings/2018/0618.pdf>

2、论文主要内容

该论文是IJCAI 2018的杰出论文（Distinguished Paper）之一，是由北京大学的万小军老师团队完成。

在自然语言生成领域，生成不同情感的文本越来越受到关注。近年来，生成对抗网络（Generative Adversarial Net, GAN）在文本生成中展现出很强大的能力。然而，GAN生成的文本通常存在质量差、缺乏多样性和模式崩塌的问题。该论文提出了一种新的框架——SentiGAN，包含多个生成器和一个多分类判别器，来解决上述问题。

图5: SentiGAN模型框架



数据来源: K Wang, X Wan 《SentiGAN: Generating Sentimental Texts via Mixture Adversarial Networks》, 广发证券发展研究中心

SentiGAN模型的整体框架如上图所示,假如想生成k类情感文本,则模型使用k个生成器和一个判别器。整个框架可以分为两个对抗的学习目标,分别是生成器的学习目标和判别器的学习目标。第i个生成器 G_i 的目标是生成第i类情感的文本,并且能够欺骗判别器;而判别器D的目标是区分生成的文本和真实的k类情感的文本,采用了多类别分类的目标函数。在论文的实验中,k设置为2,即生成积极和消极的文本。模型分别在影评(Movie Reviews, MR)、啤酒评价(Bear Reviews, BR)和用户评估(Customer Reviews, CR)三个数据集上训练,并且随机初始化维度为300的词向量。生成器是单层的LSTM网络,判别器是CNN网络。

图6: 生成文本的情感准确度对比

Accuracy	MR	BR	CR
Real Data	0.892	0.874	0.846
RNNLM	0.622	0.595	0.552
SeqGAN	0.717	0.684	0.632
VAE	0.751	0.721	0.643
SentiGAN(k=1)	0.803	0.750	0.731
C-GAN	0.822	0.773	0.762
S-VAE	0.831	0.793	0.727
SentiGAN(k=2)	0.885	0.841	0.803

数据来源: K Wang, X Wan 《SentiGAN: Generating Sentimental Texts via Mixture Adversarial Networks》, 广发证券发展研究中心

从情感准确度对比可以看出,SentiGAN模型在三个数据集上都获得了最好的结果,说明带有多个生成器和一个多类别判别器的模型能够使每个生成器更好地生成自己类别的情感文本。此外,模型在生成文本的流畅性、创新性、多样性和智能性上也都有最好的表现。

该论文的主要贡献在于：

- 1) 提出了一个新的框架SentiGAN，能够生成多类别的、多样性的、高质量的不同情感类别的文本；
- 2) 提出了一个新的基于惩罚的目标函数，使SentiGAN的每个生成器都能生成特定情感的文本，提升多样性；
- 3) 通过大量实验证明了SentiGAN模型的有效性和先进性。

五、论文： Abstractive Text Summarization

1、论文信息

论文: A Reinforced Topic-Aware Convolutional Sequence-to-Sequence Model for Abstractive Text Summarization.

论文作者: Li Wang, Junlin Yao, Yunzhe Tao, Li Zhong, Wei Liu, Qiang Du

论文来源: <https://arxiv.org/abs/1805.03616>

2、论文主要内容

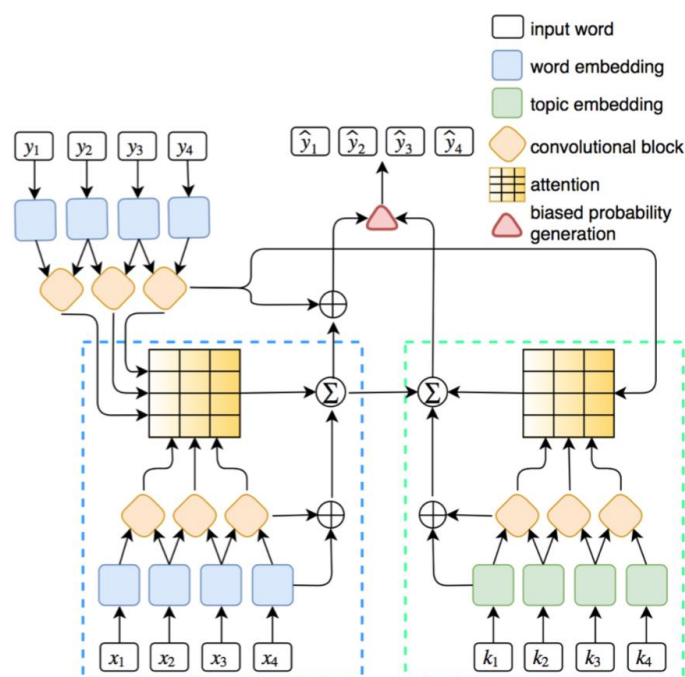
本文是腾讯和合作团队发表于IJCAI 2018的工作。

自动文本摘要在很多不同的自然语言处理应用中都发挥着重要的作用。对于文本摘要来说，概括文章的中心思想、信息丰富性、内容代表性等，都是非常重要的。自动文本摘要的关键难题在于准确评估摘要结果、选择重要信息、有效地过滤冗余内容、总结相关信息从而得到可读性强的摘要等。

自动摘要技术有两种类型，即抽取式（extraction）和抽象式（abstraction）。抽取式方法是选择源文档中的重要片段并将它们组合来生成摘要。不同于抽取式摘要，抽象方法能够针对源文档的核心思想重新组织摘要语言，并确保所生成的摘要语法正确且保证可读性；这更接近于人类做摘要的方式，因此也是本论文关注的方法。

论文提出了一种解决自动文本摘要任务的深度学习方法，即将主题信息引入到基于卷积网络的序列到序列模型（ConvS2S）中并使用Self-Critical Sequence Training（SCST）方法来进行优化。通过引入词语和主题信息，加入多步注意力机制，文章的方法可以通过带主题偏置的概率生成机制提升所生成摘要的连贯性、多样性和信息丰富性。另一方面，SCST这样的强化学习训练方法可以根据针对摘要的评价指标ROUGE直接优化模型，这也能缓解曝光偏差问题。论文在三个基准数据集上进行了广泛的实验，结果表明引入主题模型和SCST强化学习方法的卷积神经网络能生成信息更丰富更多样化的文本摘要，模型在数据集上取得了较好的文本摘要效果。

图7：引入主题信息的卷积神经网络结构



数据来源：L Wang, J Yao, Y Tao等 《A Reinforced Topic-Aware Convolutional Sequence-to-Sequence Model for Abstractive Text Summarization》，广发证券发展研究中心

论文在三个数据集上实验以测试该方法的性能。首先是带注释的Gigaword语料库，包括3.8M个训练样本，190K个验证样本和1951个测试样本，文本摘要对包括源文章的标题和第一句话。图8展示了三种ROUGE指标在Gigaword语料库中的准确度分数，以比较加入主题信息和强化学习的ConvS2S模型与其他各类神经网络模型的性能，两张图分别为样本外测试和样本内测试。测试结果表明加入主题信息和强化学习的ConvS2S模型可以显著提高文本摘要的准确性。

图8：三种ROUGE在Gigaword语料库中的准确度（左）及其内部测试集的准确度（右）

	RG-1 (F)	RG-2 (F)	RG-L (F)
ABS [Rush <i>et al.</i> , 2015]	29.55	11.32	26.42
ABS+ [Rush <i>et al.</i> , 2015]	29.76	11.88	26.96
RAS-Elman [Chopra <i>et al.</i> , 2016]	33.78	15.97	31.15
words-lvt5k-1sent [Nallapati <i>et al.</i> , 2016b]	35.30	16.64	32.62
RNN+MLE [Shen <i>et al.</i> , 2016]	32.67	15.23	30.56
RNN+MRT [Shen <i>et al.</i> , 2016]	36.54	16.59	33.44
SEASS (beam) [Zhou <i>et al.</i> , 2017]	36.15	17.54	33.63
ConvS2S [Gehring <i>et al.</i> , 2017]	35.88	17.48	33.29
Topic-ConvS2S	36.38	17.96	34.05
Reinforced-ConvS2S	36.30	17.64	33.90
Reinforced-Topic-ConvS2S	36.92	18.29	34.58

	RG-1 (F)	RG-2 (F)	RG-L (F)
ABS (beam) [Rush <i>et al.</i> , 2015]	37.41	15.87	34.70
s2s+att (greedy) [Zhou <i>et al.</i> , 2017]	42.41	20.76	39.84
s2s+att (beam) [Zhou <i>et al.</i> , 2017]	43.76	22.28	41.14
SEASS (greedy) [Zhou <i>et al.</i> , 2017]	45.27	22.88	42.20
SEASS (beam) [Zhou <i>et al.</i> , 2017]	46.86	24.58	43.53
Topic-ConvS2S	46.80	24.74	43.92
Reinforced-ConvS2S	46.68	24.22	43.76
Reinforced-Topic-ConvS2S	46.92	24.83	44.04

数据来源：L Wang, J Yao, Y Tao等 《A Reinforced Topic-Aware Convolutional Sequence-to-Sequence Model for Abstractive Text Summarization》，广发证券发展研究中心

第二个数据集是DUC-2004 test set 1，一个标准的摘要评估集，由500篇新闻文

章组成，这里统计的准确度是基于召回率的分。ConvS2S模型也获得了不错的表现。

最后是中国短文摘要（LCSTS）数据集，这是一个大规模的中文数据集，由中国微博网站新浪微博收集和构建，论文中使用LCSTS的第一部分2.4M个文本摘要对进行训练，并从最后一部分中选择具有高注释分数的725对作为测试集。由于是中文数据集，为便于全面比较，文章分别统计了基于单词的ROUGE分数和基于字符的分数。以此证明，该模型同样在中文数据集里取得优异的成绩。

图9：三种ROUGE在DUC-2004中的准确度（左）和在LCSTS中的准确度（右）（右下角的分数分为基于单词的分数和基于字符的分数）

	RG-1 (R)	RG-2 (R)	RG-L (R)		RG-1 (F)	RG-2 (F)	RG-L (F)
ABS [Rush <i>et al.</i> , 2015]	26.55	7.06	22.05	character-based preprocessing			
ABS+ [Rush <i>et al.</i> , 2015]	28.18	8.49	23.81	RNN context [Hu <i>et al.</i> , 2015]	29.90	17.40	27.20
RAS-Elman [Chopra <i>et al.</i> , 2016]	28.97	8.26	24.06	COPYNET [Gu <i>et al.</i> , 2016]	34.40	21.60	31.30
words-lvt5k-lsent [Nallapati <i>et al.</i> , 2016b]	28.61	9.42	25.24	RNN+MLE [Shen <i>et al.</i> , 2016]	34.90	23.30	32.70
RNN+MLE [Shen <i>et al.</i> , 2016]	24.92	8.60	22.25	RNN+MRT [Shen <i>et al.</i> , 2016]	38.20	25.20	35.40
RNN+MRT [Shen <i>et al.</i> , 2016]	30.41	10.87	26.79	word-based preprocessing			
SEASS (beam) [Zhou <i>et al.</i> , 2017]	29.21	9.56	25.51	RNN context [Hu <i>et al.</i> , 2015]	26.80	16.10	24.10
ConvS2S [Gehring <i>et al.</i> , 2017]	30.44	10.84	26.90	COPYNET [Gu <i>et al.</i> , 2016]	35.00	22.30	32.00
Topic-ConvS2S	31.08	10.82	27.61	Topic-ConvS2S	38.94/44.42	21.05/32.65	37.03/42.09
Reinforced-ConvS2S	30.74	10.68	27.09	Reinforced-ConvS2S	36.68/42.61	18.69/29.79	34.85/40.03
Reinforced-Topic-ConvS2S	31.15	10.85	27.68	Reinforced-Topic-ConvS2S	39.93/45.12	21.58/33.08	37.92/42.68

数据来源：L Wang, J Yao, Y Tao等 《A Reinforced Topic-Aware Convolutional Sequence-to-Sequence Model for Abstractive Text Summarization》，广发证券发展研究中心

总而言之，文章提出的加入主题信息和强化学习的ConvS2S模型，可以生成具有更多信息量，连贯性和多样性的摘要，实验证明其在数据集上取得了极好的文本摘要效果。展望未来，文章的目标是在源文本为长段或者多文档的数据集上评估该模型，而不是基于句子摘要。

六、论文：Mask R-CNN

1、论文信息

论文：Mask R-CNN

论文作者：Kaiming He, Georgia Gkioxari, Piotr Dollár, Ross Girshick

论文来源：<https://arxiv.org/abs/1703.06870>

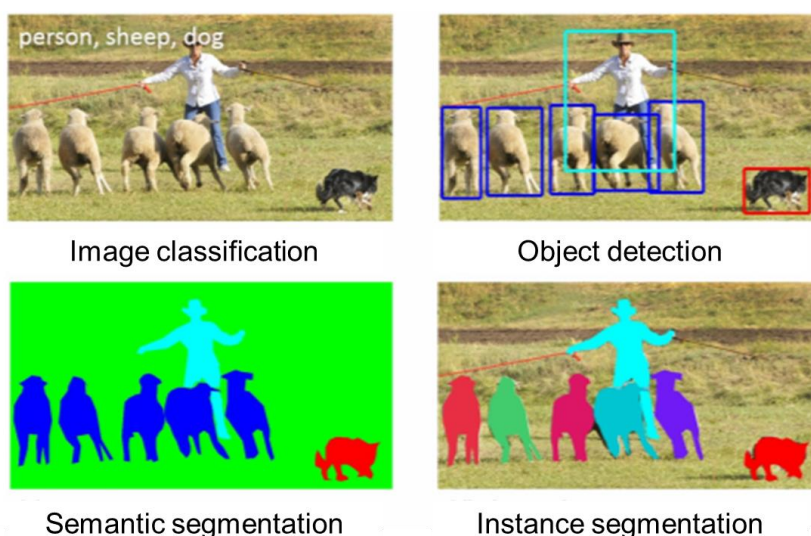
GitHub地址：<https://github.com/facebookresearch/Detectron>

2、论文主要内容

该论文是ICCV 2017的最佳论文。主要作者是著名的计算机视觉“大神”何恺明，现任职于Facebook的AI实验室。此前他已经两次获得顶级会议CVPR的最佳论文奖。

Mask R-CNN是一个简单灵活同时通用性很好的目标实例分割框架，能够有效地在每个实例中探测同时出现的目标，并对每个实例生产一个高质量的分割掩码（Segmentation Mask），即下图中覆盖实例的彩色区域。计算机视觉领域常见的任务包括图像分类（Image Classification）、目标检测（Object Detection）、语义分割（Semantic Segmentation）和实例分割（Instance Segmentation）。其中，图像分类就是判断图片的类别；目标检测能够检测出图中不同的目标；语义分割能够根据像素将不同的目标分隔开，但是无法将相同类别的目标分开；实例分割需要在语义分割的基础上对同类物体进行更精细的分割，因此难度更大。


图10：计算机视觉（Computer Vision）领域的常见任务



数据来源：TY Lin, M Maire, S Belongie等《Microsoft Coco: Common Objects in Context》，
广发证券发展研究中心

Mask R-CNN是一个非常灵活的框架，通过在模型上修改不同的分支，可以完成包括目标分类、目标检测、语义分割、实例分割甚至人体姿势识别等多种任务，而且计算速度快，准确率高。

图11: Mask R-CNN能够处理的视觉任务




数据来源: K He, G Gkioxari, P Dollár, R Girshick 《Mask R-CNN》, 广发证券发展研究中心

解析Mask R-CNN框架之前,我们首先按顺序介绍一下R-CNN, Fast R-CNN和Faster R-CNN,因为这几篇论文都是一脉相承的。

Ross Girshick在2014年的CVPR会议中提出了R-CNN (Regions with CNN features), 是利用深度学习进行目标检测的开山之作。如下图所示, R-CNN算法主要分成四个步骤,首先通过Selective Search方法从每张图像中生成约2000~3000个可能存在检测目标的候选区域;然后对每个区域,使用卷积神经网络 (Convolutional Neural Networks, CNN)提取特征;第三步使用支持向量机(SVM)对目标类别进行判断,同时使用Bounding Box Regression对目标包围框进行精细修正。

R-CNN在生成候选区域以后,再对每个区域分别提取特征,因为候选区域之间存在大量重叠,导致大量重复计算,模型的训练速度和测试速度都很慢。此外,R-CNN中分类器和回归器是完全独立训练的,对于存储空间的消耗很大。

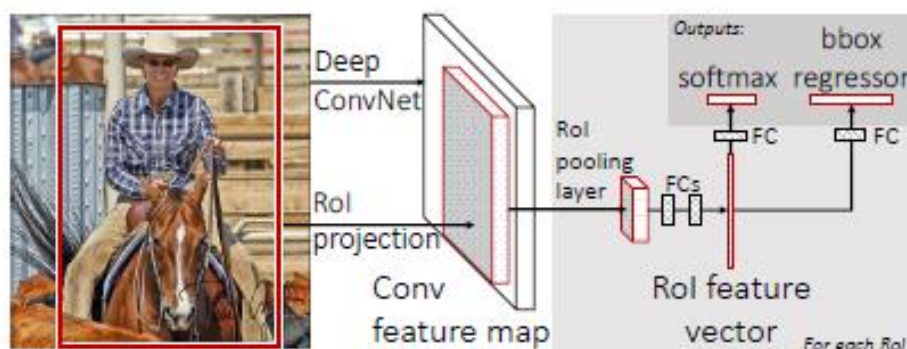
图12: R-CNN目标检测系统框架



数据来源: R Girshick, J Donahue, T Darrell, J Malik 《Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation》, 广发证券发展研究中心

基于R-CNN算法存在的问题, Ross Girshick在2015年提出了Fast R-CNN。Fast R-CNN直接采用神经网络对全图提取特征, 通过增加一个RoI Pooling Layer来获得固定大小的特征图, 避免了大量重复计算。同时, 目标类别判断和位置精调可通过同一套深度网络实现, 减少了额外的存储。

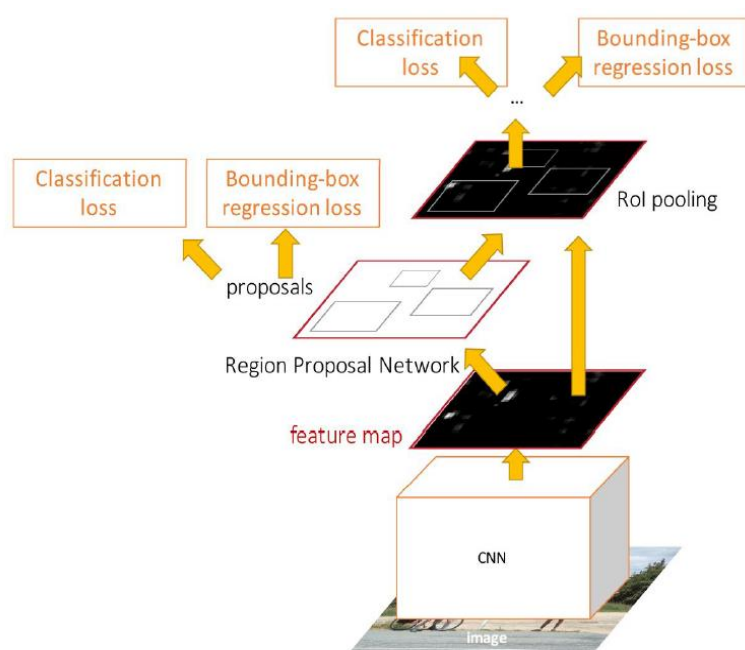
图13: Fast R-CNN目标检测系统框架



数据来源: R Girshick 《Fast R-CNN》, 广发证券发展研究中心

然而Fast R-CNN仍然采用耗时的Selective Search方法来切分图像获得候选区域。在此基础上提出的Faster R-CNN把提取候选区域的过程也加入到整个网络中, 引入候选区域网络 (Region Proposal Network, RPN) 代替Selective Search方法, 能够将生成候选区域的时间减少到几乎为0。


图14: Faster R-CNN目标检测系统框架



数据来源: S Ren, K He, R Girshick, J Sun 《Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks》, 广发证券发展研究中心

在R-CNN, Fast R-CNN和Faster R-CNN的基础上, 何恺明等人在ICCV 2017提出了Mask R-CNN, 对Faster R-CNN主要有4点提升。第一, 在目标类别判断和位置精调的基础上添加并行的生成掩码 (Mask) 的分支; 第二, 可以通过添加不同的分支, 很方便地扩展到其他计算机视觉任务, 比如人体姿态估计等; 第三, 提出RoIAlign解决了特征抽取过程中的原始图像像素和特征像素的偏差问题, 显著提升了掩码的准确度; 第四, 优化了损失函数, 进一步提升准确率。Mask R-CNN在COCO系列挑战赛的三个分支中都获得了最佳成绩, 包括实例分割、边界对象检测和人体关键点检测。Mask R-CNN 的表现优于所有现有的单一模型取得的成绩。

图15: Mask R-CNN目标检测系统框架



数据来源: K He, G Gkioxari, P Dollár, R Girshick 《Mask R-CNN》, 广发证券发展研究中心

七、论文：Adaptive Affinity Fields

1、论文信息

论文：Adaptive Affinity Fields for Semantic Segmentation.

论文作者：Tsung-Wei Ke, Jyh-Jing Hwang, Ziwei Liu, and Stella X. Yu

论文来源：<https://arxiv.org/abs/1803.10335>

GitHub地址：https://github.com/twke18/Adaptive_Affinity_Fields

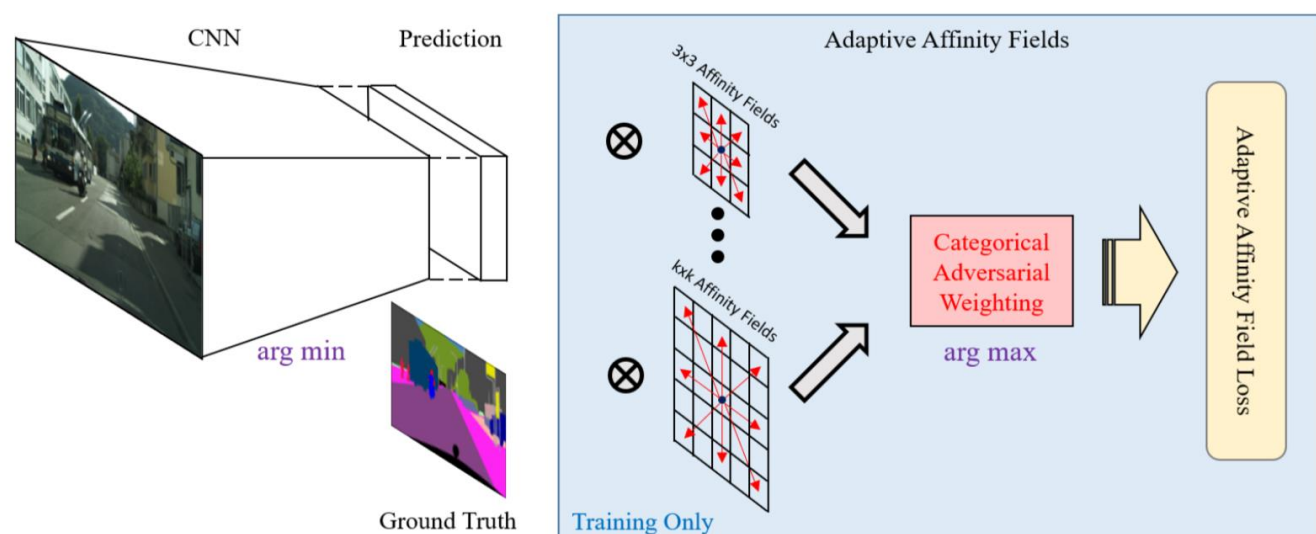
2、论文主要内容

本文是加州大学伯克利分校研究团队发表于ECCV 2018的工作。

近年来，语义分割问题通过越来越强大的图像分类器，结合条件随机场（Conditional Random Fields, CRF）或生成对抗网络（GAN）等结构先验模型，取得了极大的进展。图像的语义分割指的是为每幅图片分配分类标签的任务。CRF通过测量像素之间视觉外观的相似性来判断标签，通过消息传递算法（Message Passing Algorithms）得到最佳标记，迭代推理过程比较耗时，而且CRF对视觉外观的变化很敏感。GAN在神经网络输出层加入结构规律性的鉴别器网络，模型难以训练，特别容易出现模型不稳定和模式崩溃。

在本文中，作者提出了一种更简单的替代方案，可以在训练期间学习和验证语义分割的空间结构。与在单个像素上强制语义标签并在相邻像素之间匹配标签的现有方法不同，作者提出自适应相似场（Adaptive Affinity Fields, AAF）的概念来匹配标签空间中的相邻像素之间的语义关系。作者使用对抗性学习为每个语义类别选择最佳亲和力范围，并将这个问题转化为一个极小极大问题（Minimax Problem），利用最优的最坏情况学习（Best Worst-Case Learning）情境，在最大化多核相似性误差的基础上最大限度地减少整体匹配损失，优化语义分割神经网络。如图16所示，AAF由两部分组成：相似场损失和相应的分类对抗权重。值得注意的是，AAF仅在训练期间引入，并且在测试推断期间不存在额外的计算。

图16: AAF方法概述



数据来源: TW Ke, JJ Hwang, Z Liu, SX Yu 《Adaptive Affinity Fields for Semantic Segmentation》, 广发证券发展研究中心

AAF语义分割具有以下优点:

1. 它以分布式和以像素为中心关系对空间结构信息进行编码,提供了一种通用的表示方式。
2. 它比GAN更容易训练并且比CRF更有效,因为AAF仅在训练期间影响网络学习,在测试期间不需要额外的参数或推理过程。
3. 它更通用于视觉域变化,因为AAF对标签关系进行操作而不是像素值。

图17: CRF、GAN和AAF方法的主要区别

Method	Structure Guidance	Training	Run-time Inference	Performance
CRF [15]	input image	medium	yes	76.53
GAN [12]	ground-truth labels	hard	no	76.20
Our AAF	label affinity	easy	no	79.24

数据来源: TW Ke, JJ Hwang, Z Liu, SX Yu 《Adaptive Affinity Fields for Semantic Segmentation》, 广发证券发展研究中心

论文在PASCAL VOC 2012, Cityscapes和GTA5等数据集上证明了AAF语义分割的优越性能和跨领域的强大泛化能力。为更有说服力、更全面的评估算法有效性,文中分别使用三种评价标准: pixel-wise mIoU、instance-wise mIoU、boundary detection metrics。图18以PASCAL VOC 2012为例证明AAF的优越性能。

图18: AAF方法以PASCAL VOC 2012数据集, pixel-wise mIoU在验证集(一)、instance-wise mIoU在验证集(二)、boundary detection metrics在验证集(三)上的表现

Method	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv	mIoU
FCN	86.95	59.25	85.18	70.33	73.92	78.86	82.30	85.64	33.57	69.34	27.41	78.04	71.45	70.45	85.54	57.42	71.55	32.48	74.91	59.10	68.91
PSPNet	92.56	66.70	91.10	76.52	80.88	94.43	88.49	93.14	38.87	89.33	62.77	86.44	89.72	88.36	87.48	56.95	91.77	46.23	88.59	77.14	80.12
Affinity	88.66	59.25	87.85	72.19	76.36	80.65	80.74	87.82	35.38	73.45	30.17	79.84	68.15	73.52	87.96	53.95	75.46	37.15	76.62	73.42	71.07
AAF	88.15	67.83	87.06	72.05	76.45	85.43	80.58	88.33	35.47	72.76	31.55	79.68	67.01	77.96	88.20	50.31	73.16	42.71	78.14	73.87	71.95
GAN	92.36	65.94	91.80	76.35	77.70	95.39	89.21	93.30	43.35	89.25	61.81	86.93	91.28	87.43	87.21	68.15	90.64	49.64	88.79	73.83	80.74
Emb.	91.28	69.50	92.62	77.60	78.74	95.03	89.57	93.67	43.21	88.76	62.47	86.68	91.28	88.47	87.44	69.21	91.53	52.17	89.30	74.60	81.36
Affinity	91.52	74.74	92.09	78.17	80.73	95.70	89.52	92.83	43.29	89.21	60.33	87.50	90.96	88.77	88.88	71.00	88.54	50.61	89.64	78.22	81.80
AAF	92.97	73.68	92.49	80.51	79.73	96.15	90.92	93.42	45.11	89.00	62.87	87.97	91.32	90.28	89.30	69.05	88.92	52.81	89.05	78.91	82.39

Method	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv	mIoU
PSPNet	87.54	53.08	83.53	76.95	45.13	87.68	68.77	89.01	39.26	88.78	51.49	88.88	84.41	85.95	77.60	48.68	86.25	54.18	88.25	66.11	73.60
Affinity	89.42	61.72	84.64	79.86	57.57	88.81	71.74	88.91	44.78	89.55	52.55	91.22	86.12	87.40	81.10	58.33	85.15	60.61	88.47	68.86	76.73
AAF	89.76	61.74	84.40	81.87	58.04	89.03	73.68	90.46	46.67	89.65	55.63	91.33	85.85	88.36	81.93	59.84	84.52	62.67	89.35	68.80	77.54

Method	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv	mean
PSPNet	.694	.420	.658	.417	.624	.626	.562	.667	.297	.587	.279	.667	.608	.513	.554	.235	.547	.413	.551	.512	.527
Affinity	.745	.573	.708	.524	.693	.678	.627	.690	.455	.620	.383	.732	.655	.602	.648	.370	.583	.546	.609	.635	.610
AAF	.746	.559	.704	.524	.684	.675	.622	.701	.441	.612	.391	.728	.653	.595	.647	.355	.580	.547	.608	.628	.606

数据来源: TW Ke, JJ Hwang, Z Liu, SX Yu 《Adaptive Affinity Fields for Semantic Segmentation》, 广发证券发展研究中心

因为模型是在数据集上提取结构先验知识, 为验证跨数据集的推广能力, 而不是在训练数据集上的拟合能力, 作者使用Cityscapes训练模型, 在GTA5测试, 与基准模型相比较, 依然取得了明显的改进。

图19: 以Cityscapes为训练集, 以GTA5为测试集, AAF与基准模型的比较

Method	road	swalk	build.	wall	fence	pole	tlght	tsign	veg.	terrain	sky	person	rider	car	truck	bus	train	mbike	bike	mIoU	pix. acc
PSPNet	61.79	34.26	37.30	13.31	18.52	26.51	31.64	17.51	55.00	8.57	82.47	42.73	49.78	69.25	34.31	18.21	25.00	33.14	6.86	35.06	68.78
Affinity	75.26	30.34	44.10	12.91	20.19	29.78	31.50	23.98	64.25	11.83	74.32	48.28	49.12	67.39	25.76	23.82	20.29	41.48	5.63	36.86	75.13
AAF	83.07	27.82	51.16	10.41	18.76	28.58	31.74	24.98	61.38	12.25	70.65	50.53	48.06	53.35	26.80	20.97	24.50	39.56	9.37	36.52	78.28

数据来源: TW Ke, JJ Hwang, Z Liu, SX Yu 《Adaptive Affinity Fields for Semantic Segmentation》, 广发证券发展研究中心

总之, AAF将几何规律结合到分割模型中, 并通过对抗训练来学习具有自适应范围的局部关系。与其他替代方案相比, AAF以其有效性(可编码丰富的结构关系), 高效性(不引入推理开销)和鲁棒性(对域变化不敏感), 为深度学习中的结构建模提供了新的视角。

八、论文: Taskonomy: Disentangling Task Transfer Learning

1、论文信息

论文: Taskonomy: Disentangling Task Transfer Learning

论文作者: Amir R. Zamir, Alexander Sax, William Shen, Leonidas Guibas, Jitendra Malik, Silvio Savarese

论文来源: http://taskonomy.stanford.edu/taskonomy_CVPR2018.pdf

2、论文主要内容

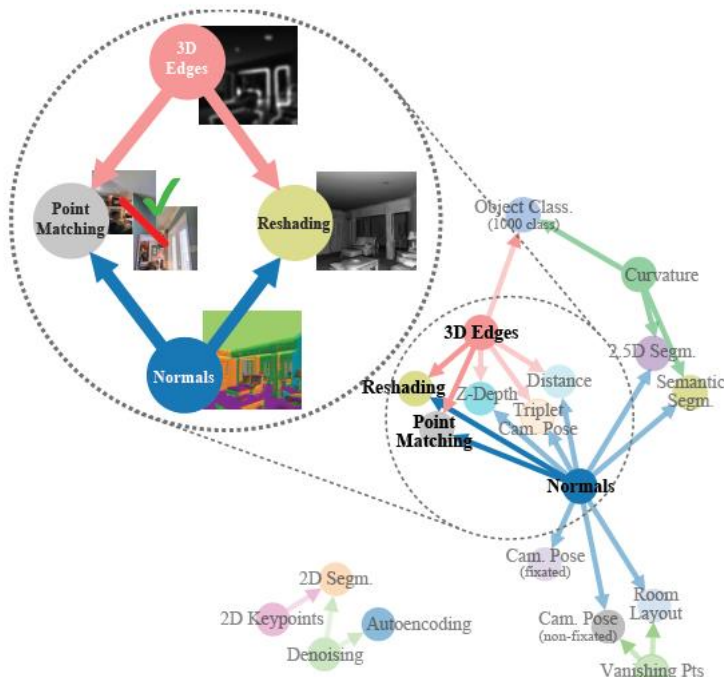
该论文是CVPR 2018的最佳论文之一,提出了一个映射视觉任务空间的框架,通过计算不同的任务之间的关联性来确定迁移学习方案,以通过更少数据来解决任务。

计算机视觉领域有许多不同的任务,如目标识别、边缘检测、深度估计等等,通常研究人员都采用逐一击破的方法处理这些任务,即对每一个任务都收集大量数据,并进行大量的计算。那么这些计算机视觉任务之间是否有相关性呢?直觉上,某些视觉任务之间是存在一种结构的,了解这种结构具有巨大的价值,它是迁移学习背后的概念,为识别不同任务间的冗余计算提供了依据。识别了任务间的冗余,就有可能在相关任务间无缝地重复使用监督或者在一个系统中解决多个问题而不增加复杂度。

该论文提出了一种完全计算的方法来构建视觉任务的空间结构,这是通过寻找26个不同视觉任务之间的迁移学习依赖关系来实现的,这些任务包括2D、2.5D、3D和语义等。该论文得到了用于任务迁移学习的计算分类图,并提供了一系列计算和探测这种分类结构的工具,包括一个可以用来设计有效监督策略的求解器。

如下图所示,在一个通过计算任务分类(Computational Task Taxonomy,简写成Taskonomy)得到的示例任务结构图中,可以发现将通过曲面法估计器(Surface Normal Estimator)和遮挡边缘检测器(Occlusion Edge Detector)学习到的特征结合起来,可以用少量标记数据就快速训练用于重描影(Reshading)和点匹配(Point Matching)的优质网络。

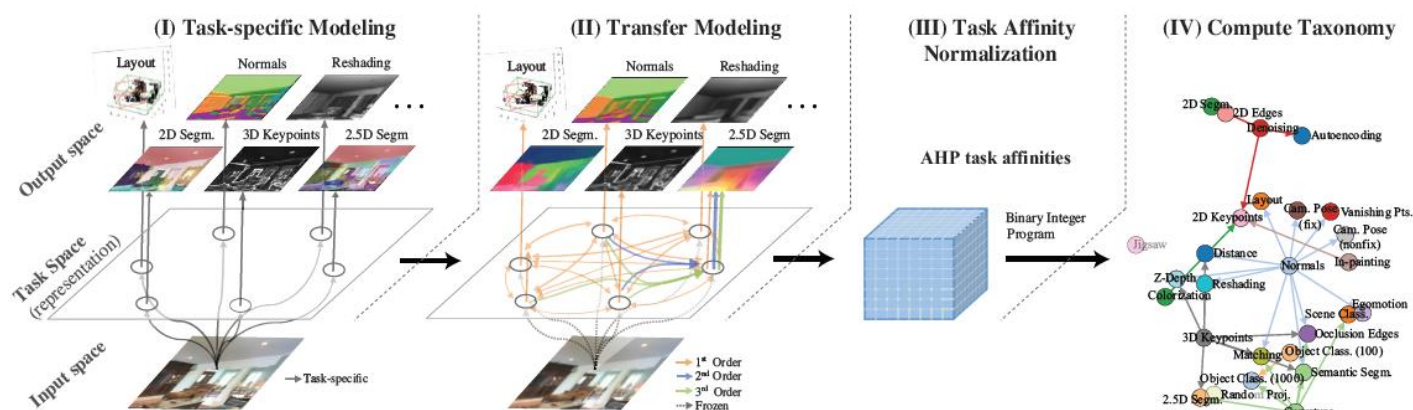
图20：一个通过计算任务分类得到的示例任务结构图



数据来源：AR Zamir, A Sax, W Shen 等 《Taskonomy: Disentangling Task Transfer Learning》，广发证券发展研究中心

Taskonomy是一项量化不同视觉任务之间关联，并利用这些关联来最优化学习策略的研究。

图21：Taskonomy计算过程图



数据来源：AR Zamir, A Sax, W Shen 等 《Taskonomy: Disentangling Task Transfer Learning》，广发证券发展研究中心

如上图所示，Taskonomy可以通过四个步骤来得到，前三个步骤是要量化不同视觉任务之间的关联，并将任务关联表达成一个关联矩阵（Affinity Matrix）。最后一步是根据关联矩阵进行最优化，求得如何最高效地去学习一组任务，这个最高效的策略会由一个指向图（Directed Graph）来表示，这个指向图被称为Taskonomy。词语上，Taskonomy是Task（任务）和 Taxonomy（分类论）的合并简称。

最终的实验表明，视觉任务之间确实存在很强的关联性，Taskonomy可以利用这种关联性，通过更少的数据很好的解决一组任务。

九、论文：Graph Networks

1、论文信息

论文：Relational Inductive Biases, Deep Learning, and Graph Networks.

论文作者：Peter W. Battaglia, Jessica B. Hamrick, Victor Bapst, Alvaro Sanchez-Gonzalez, Vinicius Zambaldi, Mateusz Malinowski, Andrea Tacchetti, David Raposo, Adam Santoro, Ryan Faulkner, Caglar Gulcehre, Francis Song, Andrew Ballard, Justin Gilmer, George Dahl, Ashish Vaswani, Kelsey Allen, Charles Nash, Victoria Langston, Chris Dyer, Nicolas Heess, Daan Wierstra, Pushmeet Kohli, Matt Botvinick, Oriol Vinyals, Yujia Li, Razvan Pascanu.

论文来源：<https://arxiv.org/abs/1806.01261v3>

GitHub地址：https://github.com/deepmind/graph_nets

2、论文主要内容

深度学习精于从数据中学习特征和进行分类，但一直面临着难以进行关系推理的问题，很多研究希望通过其他方法让计算机学会“思考”。由DeepMind、谷歌大脑、MIT 和爱丁堡大学等公司和机构的27位科学家共同提交的论文《Relational inductive biases, deep learning, and graph networks》引起了人们的关注。该研究提出了一个基于关系归纳偏置的 AI 框架：图网络（Graph Networks, GN）。研究人员称，该方法推广并扩展了各种神经网络方法，并为操作结构化知识和生成结构化行为提供了新的思路。

目前，超越经验的泛化能力仍然是现代人工智能的不足之处，深度学习在复杂的语言和场景理解、对结构化数据进行推理、在训练条件之外转移学习以及从少量经验中学习等方面面临关键挑战。本文认为组合归纳是人工智能实现与人类相似能力的首要任务，而结构化表示和计算是实现这一目标的关键。文章探索在深度学习架构中使用关系归纳偏置如何有助于学习实体、关系以及构成它们的规则。为具有强烈关系归纳偏置的AI工具提出了一个新构造块——图网络，它泛化并扩展了各种对图进行操作的神经网络方法，并为操作结构化知识和产生结构化行为提供了直接的界面。文章讨论图网络如何支持关系推理和组合归纳，为更复杂的、可解释的和灵活的推理模式奠定基础。

当学习器去预测其未遇到过的输入的结果时，会做一些假设。而机器学习算法中的归纳偏置则是这些假设的集合。关系归纳偏置（Relational Inductive Biases）是应用了关系推理的归纳偏置。

本文提出的GN框架定义了一类对图结构表征进行关系推理的函数。该 GN 框架泛化并扩展了多种图神经网络、MPNN 和 NLNN 方法，并支持从简单的构建模块建立复杂的架构。

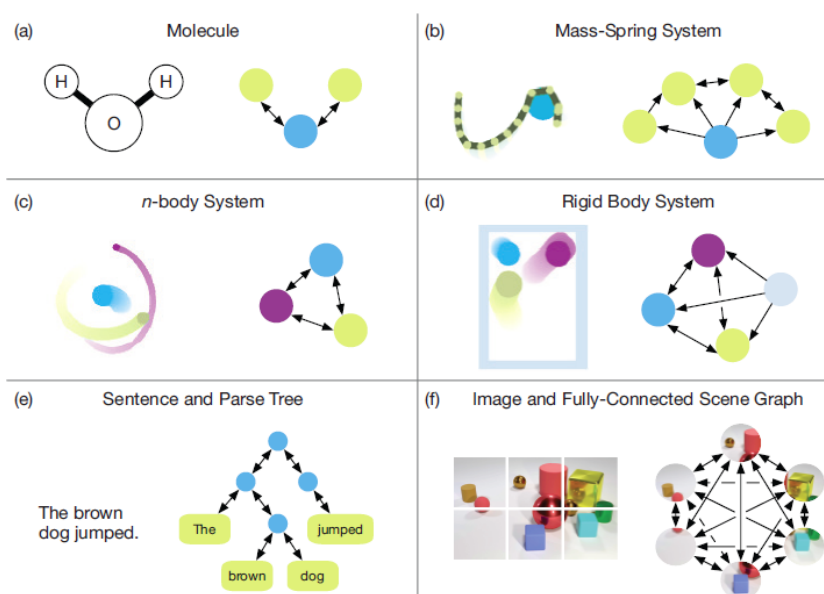
GN 框架的主要计算单元是 GN 模块，这是一个「图到图」的模块，以图作为输入，在结构层面上执行计算，并返回一个图作为输出。GN 框架的模块组织强调了可定制性，并能合成可以表达关系归纳偏置的新架构。其关键的设计原则是：灵活的表征；可配置的模块内部结构；以及可组合的多模块框架。

任何一个GN都包含节点（实体）、连边（关系）、全局信息这样三个大的信息单元，每个单元都可以被表征为一个向量。相比于深度学习只能更新权重，GN的学习发生于每一个环节上，包括对连边状态的更新、节点状态的更新和全局信息的更新。

GN的结构使得它很自然地支持组合归纳，因为GN不仅在系统级别执行计算，而且还在实体和关系的基础上进行计算。这允许对之前没有训练过的系统进行推理。目前已经有一部分研究结论展示了GN结构进行组合归纳的能力。

下图展示了用GN描述不同的系统：（a）一个分子，其中每个原子表示为对应关系的节点和边；（b）一个质量弹簧系统，其中绳索由在图中表示为节点的质量序列定义；（c）一个 n 主体系统，其中主体是节点，底层图是完全连接的；（d）一个封闭的主体系统，其中球和壁是节点，底层图形定义球之间以及球和壁之间的相互作用；（e）一个句子，其中单词对应于树中的叶子，其他节点和边可以由解析器提供；（f）一张图像，可以分解成与完全连接图像中的节点相对应的图像块。

图22：不同系统的图网络描述



数据来源：PW Battaglia, JB Hamrick, V Bapst等 《Relational Inductive Biases, Deep Learning, and Graph Networks》，广发证券发展研究中心

十、论文：Relational Deep Reinforcement Learning

1、论文信息

论文：Relational Deep Reinforcement Learning.

论文作者：Vinicius Zambaldi, David Raposo, Adam Santoro, Victor Bapst, Yujia Li, Igor Babuschkin, Karl Tuyls, David Reichert, Timothy Lillicrap, Edward Lockhart, Murray Shanahan, Victoria Langston, Razvan Pascanu, Matthew Botvinick, Oriol Vinyals, Peter Battaglia

论文来源：<https://arxiv.org/abs/1806.01830>

2、论文主要内容

本文是DeepMind团队发表的论文。

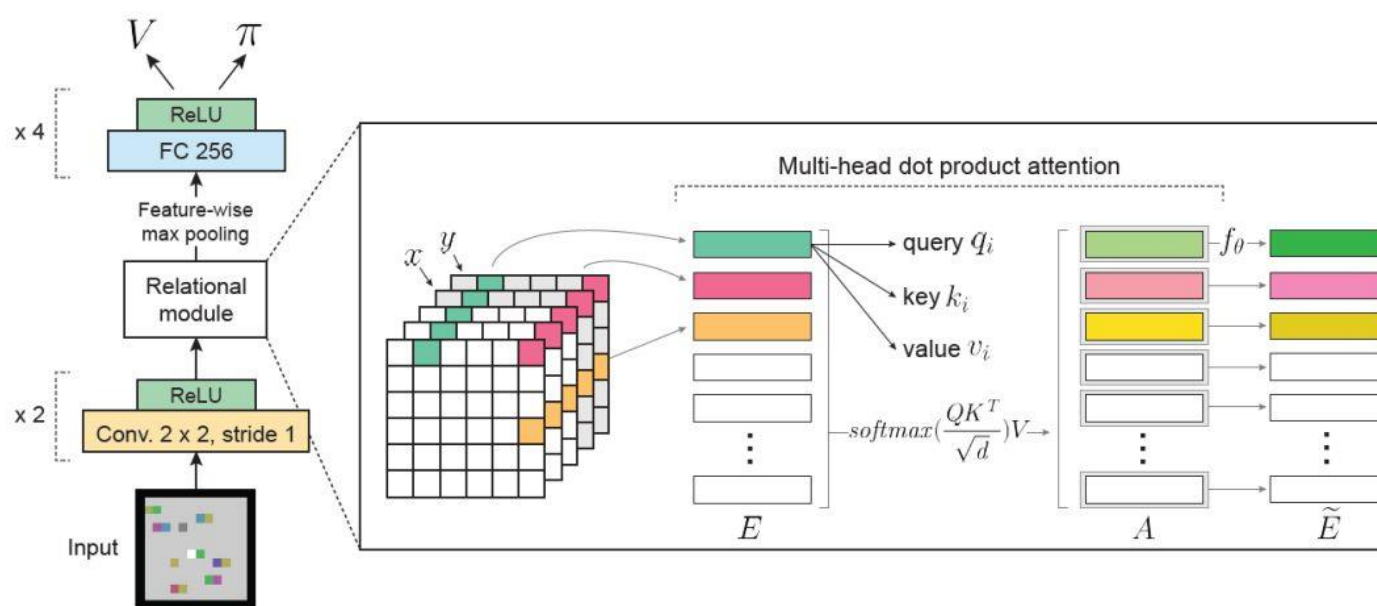
文章介绍了一种深度强化学习（Deep Reinforcement Learning）的方法，该方法通过结构化感知和关系推理提高传统强化学习的效率，泛化能力和可解释性。它使用“自我注意”（self-attention）方法来迭代地推理场景中实体之间的关系并指导无模型（model-free）策略。论文结果表明，在名为Box-World的任务规划测试中，该智能体找到了可解释的解决方案，在复杂样本下表现不错，而且能推广到更复杂的场景下。在StarCraft II训练环境下的六项子任务中，该智能体的性能已经超过了四个人类大师。

RRL（Relational Reinforcement Learning）的核心思想是使用一阶（或关系）语言表示状态、动作和策略，将强化学习与关系学习或归纳逻辑编程结合起来。从命题转向关系表征有利于目标、状态和动作的泛化，并利用早期学习阶段中获得的知识。此外，关系语言还有利于使用背景知识，而背景知识同时也可以通过与学习问题相关的逻辑和规则提供。

该论文的贡献主要基于两点：非局部计算和迭代计算。文章的智能体采用一个共享函数，计算环境中所有实体之间的两两关系，包括不同距离的实体之间的关系，其结果优于只考虑局部实体关系的智能体。此外，迭代计算可以更好地捕获实体之间的高阶交互。

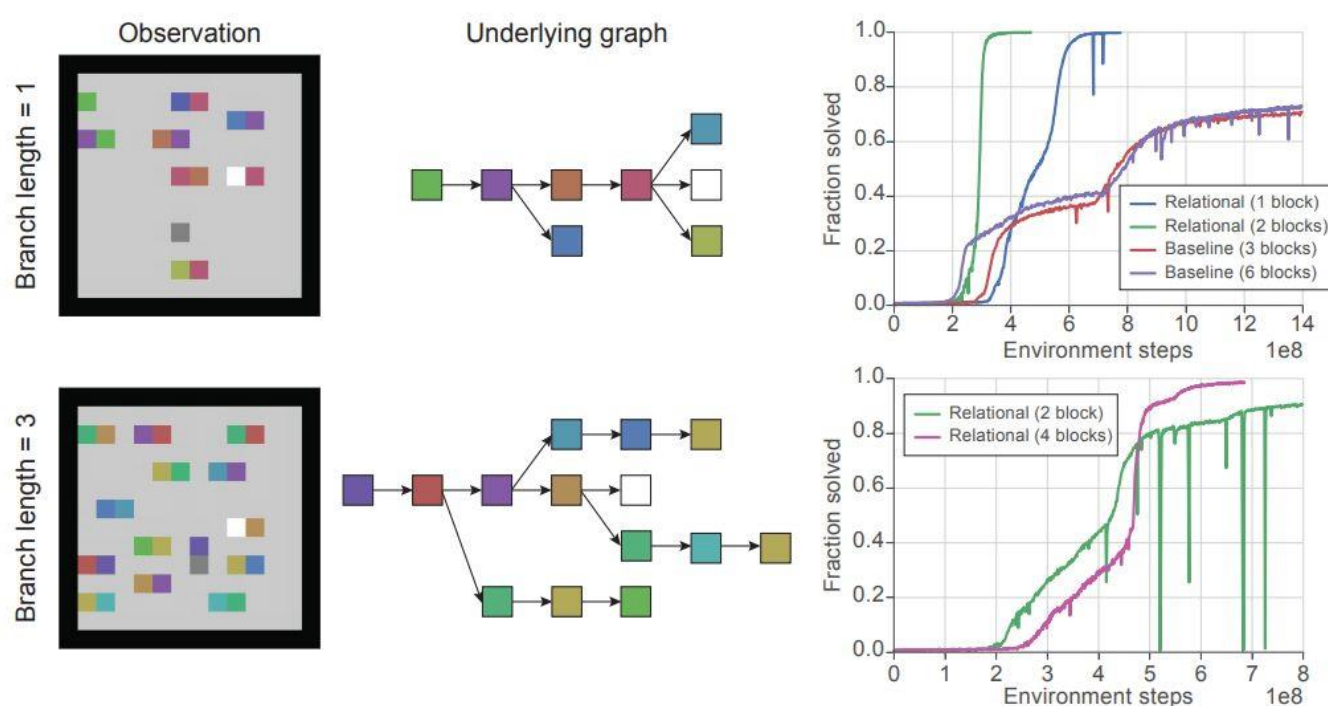
对于二维的图像输入信号，论文给出的基本假设是实体处于空间中的不同位置。通过卷积神经网络提取特征，可以获得不同的“实体”。对于不同实体，论文采用了一种多头点乘注意力模型（Multi-Head Dot-Product Attention, MHDPA）来表示实体之间的关系。通过注意力模型，神经网络可以在学习实体的同时，学习实体之间的关系。

图23: Box-World智能体架构



数据来源: V Zambaldi, D Raposo, A Santoro等 《Relational Deep Reinforcement Learning》, 广发证券发展研究中心

图24: Box-World观察值示例(左)、基本图结构(中)和训练曲线(右)



数据来源: V Zambaldi, D Raposo, A Santoro等 《Relational Deep Reinforcement Learning》, 广发证券发展研究中心

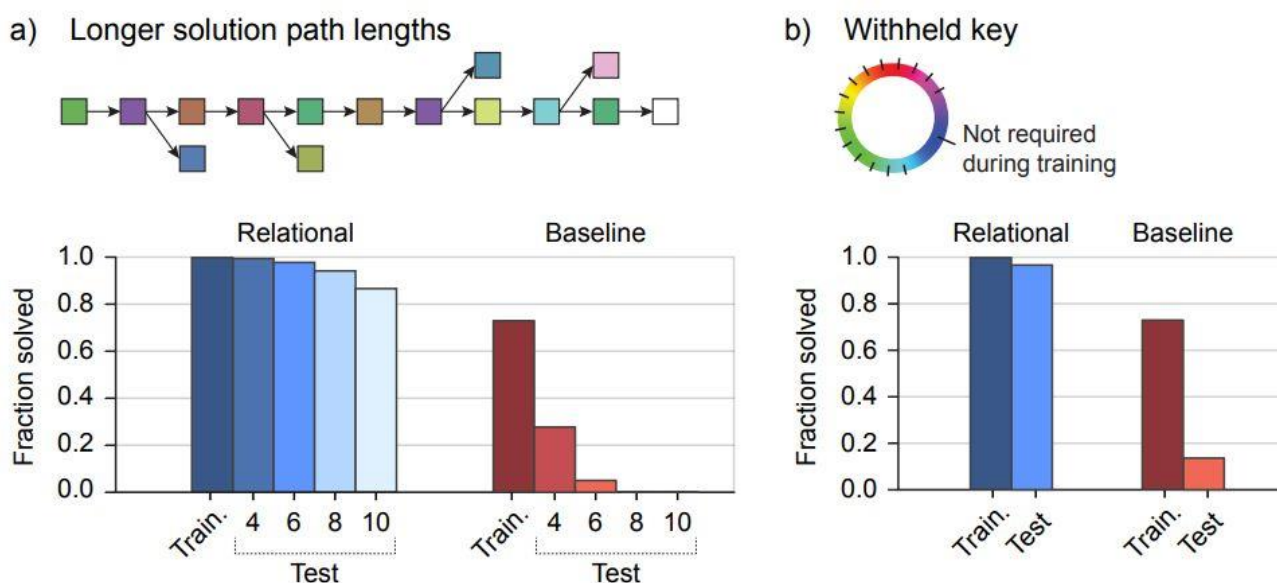
文章通过Box-World和StarCraft II两个实验来体现RRL的性能。Box-World的实验是一个感知简单但组合复杂的环境,需要抽象的关系推理和规划。它由一个12x12像素的空间组成,钥匙和方块随意散落。这个空间包含一个智能体,由一个暗灰色

像素表示，它可以在四个方向上移动：上、下、左、右。

在实验当中使用关系模块增强的智能体在该任务的两个测试中实现了接近最佳的性能，解决程度超过98%，相比之下，对照组的解决程度只有不到75%。

在RRL的泛化能力测试中可以看出，使用关系模块增强的智能体在所有序列长度条件下性能都保持在88%以上，而没有关系模块的智能体随着测试序列的增加，性能下降明显。总之，RRL相比传统的神经网络，在一定程度上能将零次学习迁移（zero-shot transfer）应用到更复杂的问题当中。

图25：RRL的泛化能力比较



数据来源：V Zambaldi, D Raposo, A Santoro等 《Relational Deep Reinforcement Learning》，广发证券发展研究中心

文章从StarCraft II环境中采取了7个不同的小游戏进行测试。这些小游戏表示不同的游戏场景，可以作为完整StarCraft II游戏的一种简化。相对于完整的StarCraft II游戏，小游戏更方便设置增强学习的奖励机制。

在StarCraft II游戏中，具有关系模块增强的智能体同样实现了相比对照组相同或者更好的结果，在6款迷你游戏中，其性能已经超过了其中四个游戏的人类大师。

图26: StarCraft II游戏中各类动作得分

Agent	Mini-game						
	①	②	③	④	⑤	⑥	⑦
DeepMind Human Player [15]	26	133	46	41	729	6880	138
StarCraft Grandmaster [15]	28	177	61	215	727	7566	133
Random Policy [15]	1	17	4	1	23	12	< 1
FullyConv LSTM [15]	26	104	44	98	96	3351	6
PBT-A3C [31]	—	101	50	132	125	3345	0
Relational agent	27	196 ↑	62 ↑	303 ↑	736 ↑	4906	123
Control agent	27	187 ↑	61	295 ↑	602	5055	120

数据来源: V Zambaldi, D Raposo, A Santoro等 《Relational Deep Reinforcement Learning》, 广发证券发展研究中心

总之, 通过将结构化感知和关系推理引入Deep RL架构, RRL智能体可以学习可解释的表示, 并在样本复杂性, 概括能力和整体性能方面都超越了基准。这证明了将RRL与深度学习相结合的优势巨大。

十一、论文: The Trade-Offs of Large Scale Learning

1、论文信息

论文: The Trade-Offs of Large Scale Learning

论文作者: Le'on Bottou, Olivier Bousquet

论文来源:

<http://papers.nips.cc/paper/3323-the-tradeoffs-of-large-scale-learning.pdf>

2、论文主要内容

在2018年年底举办的机器学习顶级会议NeurIPS上, 此前发表在NIPS (该缩略词因包含种族等含义, 2018年改成NeurIPS) 2007会议上的《The Trade-Offs of Large Scale Learning》被授予时间检验奖 (Test of Time Award)。在新技术层出不穷的机器学习领域, 许多曾经的研究热点都被别的东西取代了, 因此这篇论文能够在经历时间的考验后获得这个奖项, 是极高的荣誉。

该论文是机器学习界、尤其是深度学习发展道路上非常重要的论文, 它是推动研究人员不断建立并使用更大的数据集的理念来源之一。该论文提出了一套理论框架, 能够考虑近似优化方法对学习算法的影响, 分析表明小规模的学习问题和大规模的机器学习问题在训练时, 面临显著不同的权衡条件。

许多机器学习模型都可以看成两部分的组合, 第一是模型F, 可以看成是不同的拟合函数的集合, 第二部分是优化算法, 具体描述如何找出效果最好的那个函数。

在此基础上，模型的经验误差可以分解成三个子项，分别是近似误差 ϵ_{app} 、估计误差 ϵ_{est} 和优化误差 ϵ_{opt} ，其中 ϵ_{app} 表示F与理论上的完美解之间的误差， ϵ_{est} 表示根据训练得到的函数与理论上F内最优的函数的误差， ϵ_{opt} 表示因训练时长有限而提前终止带来的误差。

对于小规模学习问题，主要受到样本量的制约，计算时间不成问题，因此 ϵ_{opt} 可以趋近于零，主要在近似误差 ϵ_{app} 和估计误差 ϵ_{est} 之间做权衡。具体是，越复杂的模型F，近似误差 ϵ_{app} 越小，但是很难找到F中最优的函数，因此估计误差 ϵ_{est} 越大。而对于大规模的机器学习问题，主要受到训练时间的制约，因此还需权衡优化算法的复杂度。

作者的研究表明对于大规模的机器学习问题，模型的泛化性能同时受到估算过程和优化算法复杂程度的制约，在训练时间有限的情况下，最好的优化算法不一定是最好的学习算法，而一些近似的优化算法（如SGD）可能更加适合；对单样本进行少量计算，在相同训练时间限制下能够处理更多的样本，效果比取少量样本进行复杂计算要好。

风险提示

本报告为人工智能学术论文解读，不构成任何投资建议。

广发证券—行业投资评级说明

- 买入： 预期未来 12 个月内，股价表现强于大盘 10%以上。
- 持有： 预期未来 12 个月内，股价相对大盘的变动幅度介于-10%~+10%。
- 卖出： 预期未来 12 个月内，股价表现弱于大盘 10%以上。

广发证券—公司投资评级说明

- 买入： 预期未来 12 个月内，股价表现强于大盘 15%以上。
- 增持： 预期未来 12 个月内，股价表现强于大盘 5%-15%。
- 持有： 预期未来 12 个月内，股价相对大盘的变动幅度介于-5%~+5%。
- 卖出： 预期未来 12 个月内，股价表现弱于大盘 5%以上。

联系我们

	广州市	深圳市	北京市	上海市	香港
地址	广州市天河北路 183 号大都会广场 5 楼	深圳市福田区益田路 6001 号太平金融大厦 31 层	北京市西城区月坛北街 2 号月坛大厦 18 层	上海市浦东新区世纪大道 8 号国金中心一期 16 楼	香港中环干诺道中 111 号永安中心 14 楼
邮政编码	510075	518026	100045	200120	1401-1410 室
客服邮箱	gfyf@gf.com.cn				

法律主体声明

本报告由广发证券股份有限公司或其关联机构制作，广发证券股份有限公司及其关联机构以下统称为“广发证券”。本报告的分销依据不同国家、地区的法律、法规和监管要求由广发证券于该国家或地区的具有相关合法合规经营资质的子公司/经营机构完成。

广发证券股份有限公司具备中国证监会批复的证券投资咨询业务资格，接受中国证监会监管，负责本报告于中国（港澳台地区除外）的分销。

广发证券（香港）经纪有限公司具备香港证监会批复的就证券提供意见（4 号牌照）的牌照，接受香港证监会监管，负责本报告于中国香港地区的分销。

本报告署名研究人员所持中国证券业协会注册分析师资质信息和香港证监会批复的牌照信息已于署名研究人员姓名处披露。

重要声明

广发证券股份有限公司及其关联机构可能与本报告中提及的公司寻求或正在建立业务关系，因此，投资者应当考虑广发证券股份有限公司及其关联机构因可能存在的潜在利益冲突而对本报告的独立性产生影响。投资者不应仅依据本报告内容作出任何投资决策。

本报告署名研究人员、联系人（以下均简称“研究人员”）针对本报告中相关公司或证券的研究分析内容，在此声明：（1）本报告的全部分析结论、研究观点均精确反映研究人员于本报告发出当日的关于相关公司或证券的所有个人观点，并不代表广发证券的立场；（2）研究人员的部分或全部的报酬无论在过去、现在还是将来均不会与本报告所述特定分析结论、研究观点具有直接或间接的联系。

研究人员制作本报告的报酬标准依据研究质量、客户评价、工作量等多种因素确定，其影响因素亦包括广发证券的整体经营收入，该等经营收入部分来源于广发证券的投资银行类业务。

本报告仅面向经广发证券授权使用的客户/特定合作机构发送，不对外公开发布，只有接收人才可以使用，且对于接收人而言具有保密义务。广发证券并不因相关人员通过其他途径收到或阅读本报告而视其为广发证券的客户。在特定国家或地区传播或者发布本报告可能违反当地法律，广发证券并未采取任何行动以允许于该等国家或地区传播或者分销本报告。

本报告所提及证券可能不被允许在某些国家或地区内出售。请注意，投资涉及风险，证券价格可能会波动，因此投资回报可能会有所变化，过

去的业绩并不保证未来的表现。本报告的内容、观点或建议并未考虑任何个别客户的具体投资目标、财务状况和特殊需求，不应被视为对特定客户关于特定证券或金融工具的投资建议。本报告发送给某客户是基于该客户被认为有能力独立评估投资风险、独立行使投资决策并独立承担相应风险。

本报告所载资料的来源及观点的出处皆被广发证券认为可靠，但广发证券不对其准确性、完整性做出任何保证。报告内容仅供参考，报告中的信息或所表达观点不构成所涉证券买卖的出价或询价。广发证券不对因使用本报告的内容而引致的损失承担任何责任，除非法律法规有明确规定。客户不应以本报告取代其独立判断或仅根据本报告做出决策，如有需要，应先咨询专业意见。

广发证券可发出其它与本报告所载信息不一致及有不同结论的报告。本报告反映研究人员的不同观点、见解及分析方法，并不代表广发证券的立场。广发证券的销售人员、交易员或其他专业人士可能以书面或口头形式，向其客户或自营交易部门提供与本报告观点相反的市场评论或交易策略，广发证券的自营交易部门亦可能会有与本报告观点不一致，甚至相反的投资策略。报告所载资料、意见及推测仅反映研究人员于发出本报告当日的判断，可随时更改且无需另行通告。广发证券或其证券研究报告业务的相关董事、高级职员、分析师和员工可能拥有本报告所提及证券的权益。在阅读本报告时，收件人应了解相关的权益披露（若有）。

权益披露

(1)广发证券（香港）跟本研究报告所述公司在过去 12 个月内并没有任何投资银行业务的关系。

版权声明

未经广发证券事先书面许可，任何机构或个人不得以任何形式翻版、复制、刊登、转载和引用，否则由此造成的一切不良后果及法律责任由私自翻版、复制、刊登、转载和引用者承担。